INSTITUTO TECNOLÓGICO Y DE ESTUDIOS SUPERIORES DE MONTERREY

MNA - Maestría Inteligencia Artificial Aplicada

Avance 1. Análisis exploratorio de datos

Jeanette Ríos Martínez **A01688888**

Ali Mateo Campos Martínez **A01796071**

Ali Alfonso Rico Vázquez **A01350630**

Docente Titular:

Dra. Grettel Barceló Alonso

Dr. Luis E. Falcón Morales

Docente Asistente:

Mtra. Verónica Sandra Guzmán de Valle

Asesor de proyecto:

Dr. Guillermo Mota Medina

Sports Bet Engine

12 Mayo 2026

Análisis Exploratorio de Datos **3**
Análisis Exploratorio de Datos (NBA - JUGADORES) **4**
Análisis Exploratorio de Datos (FÚTBOL - EQUIPOS) **16**
Referencias **26**

Análisis Exploratorio de Datos

¿Hay valores faltantes en el conjunto de datos? ¿Se pueden identificar patrones de ausencia?

¿Cuáles son las estadísticas resumidas del conjunto de datos?

¿Hay valores atípicos en el conjunto de datos?

¿Cuál es la cardinalidad de las variables categóricas?

¿Existen distribuciones sesgadas en el conjunto de datos? ¿Necesitamos aplicar alguna transformación no lineal?

¿Se identifican tendencias temporales? (En caso de que el conjunto incluya una dimensión de tiempo).

¿Hay correlación entre las variables dependientes e independientes?

¿Cómo se distribuyen los datos en función de diferentes categorías? (análisis bivariado)

¿Se deberían normalizar las imágenes para visualizarlas mejor?

¿Hay desequilibrio en las clases de la variable objetivo?

Análisis Exploratorio de Datos (NBA - JUGADORES)

Solo seleccionamos estas columnas debido a que las demás son una combinación de nuestras columnas objetivo (Puntos, Asistencias, Rebotes) las cuales podrían ocasionar una fuga de datos para nuestro modelo. Y el jugador analizado es Nikola Jokic.

```
features = [
    # Fechas
    'SEASON_YEAR', 'GAME_DATE',

    # Resultado del partido
    'WL',

    # Variables objetivo
    'PTS', 'REB', 'AST',
    # Básicos
    'MIN',        # Minutos de juego .

    # Tiros (volumen + eficiencia)
    'FGA', 'FGM', 'FG3A', 'FG3M', 'FTA', 'FTM',

    # Otras estadísticas
    'TOV',        # Pérdidas de balón (Turnovers).
    'STL',        # Robos de balón (Steals).
    'BLK',        # Tapones realizados (Blocks).
    'PF',         # Faltas personales (Personal Fouls).
    'PLUS_MINUS', # Diferencia de puntos del equipo cuando el jugador está en cancha.
]
```

¿Hay valores faltantes en el conjunto de datos? ¿Se pueden identificar patrones de ausencia?

No, no hay valores faltantes en las columnas que seleccionamos para el análisis. Esto es debido a que la API gratuita que utilizamos se basa en la federación más importante de baloncesto a nivel mundial (NBA), lo que nos asegura no solo la calidad del dato, sino que también la no ausencia de los mismos.

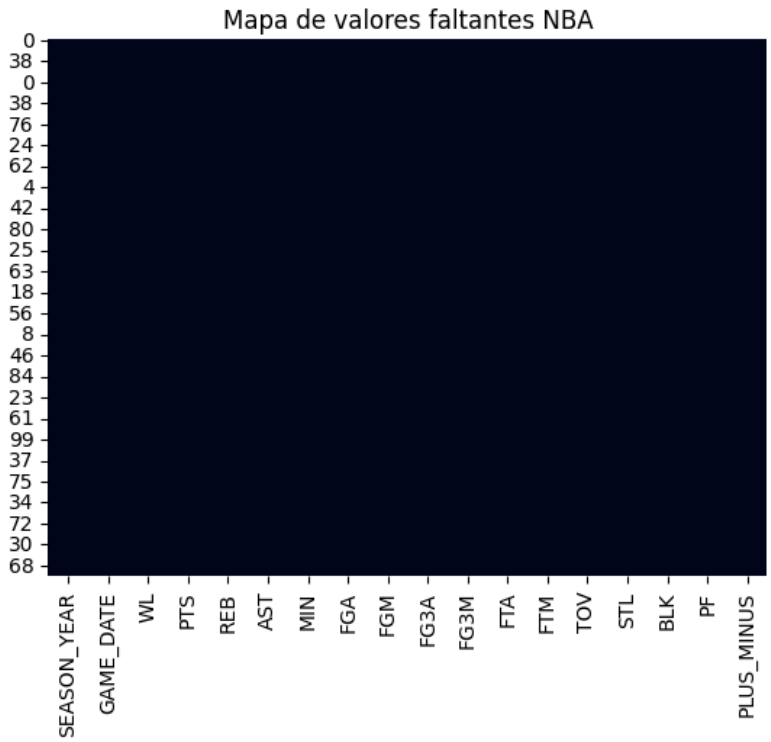

¿Cuáles son las estadísticas resumidas del conjunto de datos?

Cuando analizamos estadísticas resumidas de un jugador en concreto, es siempre impresionante observar los valores máximos que ha realizado en un partido, nos da una idea de lo bueno o increíble que es el jugador, por ejemplo, aquí vemos cómo Jokic en un partido llegó a anotar más de 60 puntos, es decir, imagina que un jugador anota la mitad del marcador global de todo el equipo.

También es importante ver los promedios, pueden ser estadísticas engañosas, pero nos da una idea clara de la importancia del jugador para su equipo, en este caso, vemos promedios que indican que es un jugador importante para el equipo del jugador.

	count	mean	std	min	25%	50%	75%	max
PTS	969.0	22.097007	10.074458	0.000000	15.000	22.000000	29.000000	61.000000
REB	969.0	10.943240	4.365042	0.000000	8.000	11.000000	14.000000	27.000000
AST	969.0	7.300310	3.890231	0.000000	4.000	7.000000	10.000000	22.000000
MIN	969.0	31.974701	7.398479	0.658333	27.975	33.713333	36.866667	64.971667
FGA	969.0	15.155831	6.669862	0.000000	10.000	15.000000	20.000000	39.000000
FGM	969.0	8.422085	3.948319	0.000000	6.000	8.000000	11.000000	22.000000
FG3A	969.0	3.216718	2.512055	0.000000	1.000	3.000000	5.000000	14.000000
FG3M	969.0	1.170279	1.216665	0.000000	0.000	1.000000	2.000000	7.000000
FTA	969.0	4.960784	3.703710	0.000000	2.000	4.000000	7.000000	24.000000
FTM	969.0	4.082559	3.193711	0.000000	2.000	4.000000	6.000000	22.000000
TOV	969.0	2.985552	1.952906	0.000000	2.000	3.000000	4.000000	10.000000
STL	969.0	1.267286	1.157875	0.000000	0.000	1.000000	2.000000	7.000000
BLK	969.0	0.725490	0.890132	0.000000	0.000	0.000000	1.000000	5.000000
PF	969.0	2.723426	1.422182	0.000000	2.000	3.000000	4.000000	6.000000
PLUS_MINUS	969.0	5.041280	12.548186	-36.000000	-3.000	6.000000	14.000000	40.000000

Aunque no es nuestro objetivo, en los deportes siempre es importante observar la influencia de la victoria y la derrota (en la NBA no existe el empate, una ventaja a nuestro favor).

Además de observar que en la NBA se juegan muchos partidos más que en el fútbol, vemos también que la derrota no tiene un peso tan grande, esto debido a que si bien ha ganado más partidos, ha perdido una cantidad considerable.

	count	unique	top	freq
WL	969	2	W	581

	count
WL	
W	581
L	388

¿Hay valores atípicos en el conjunto de datos?

Sí, encontramos muy pocas anomalías que pueden ser excelentes para darle variedad a los datos y así no dejar que nuestros modelos caigan en un sobreajuste.

El único campo con valores atípicos “preocupante” puede ser los minutos jugados, encontramos muchos valores por debajo de 15 minutos, esto puede ser debido a los primeros partidos del jugador en la NBA, sin embargo, no consideramos que sean demasiados como para eliminar las columnas.

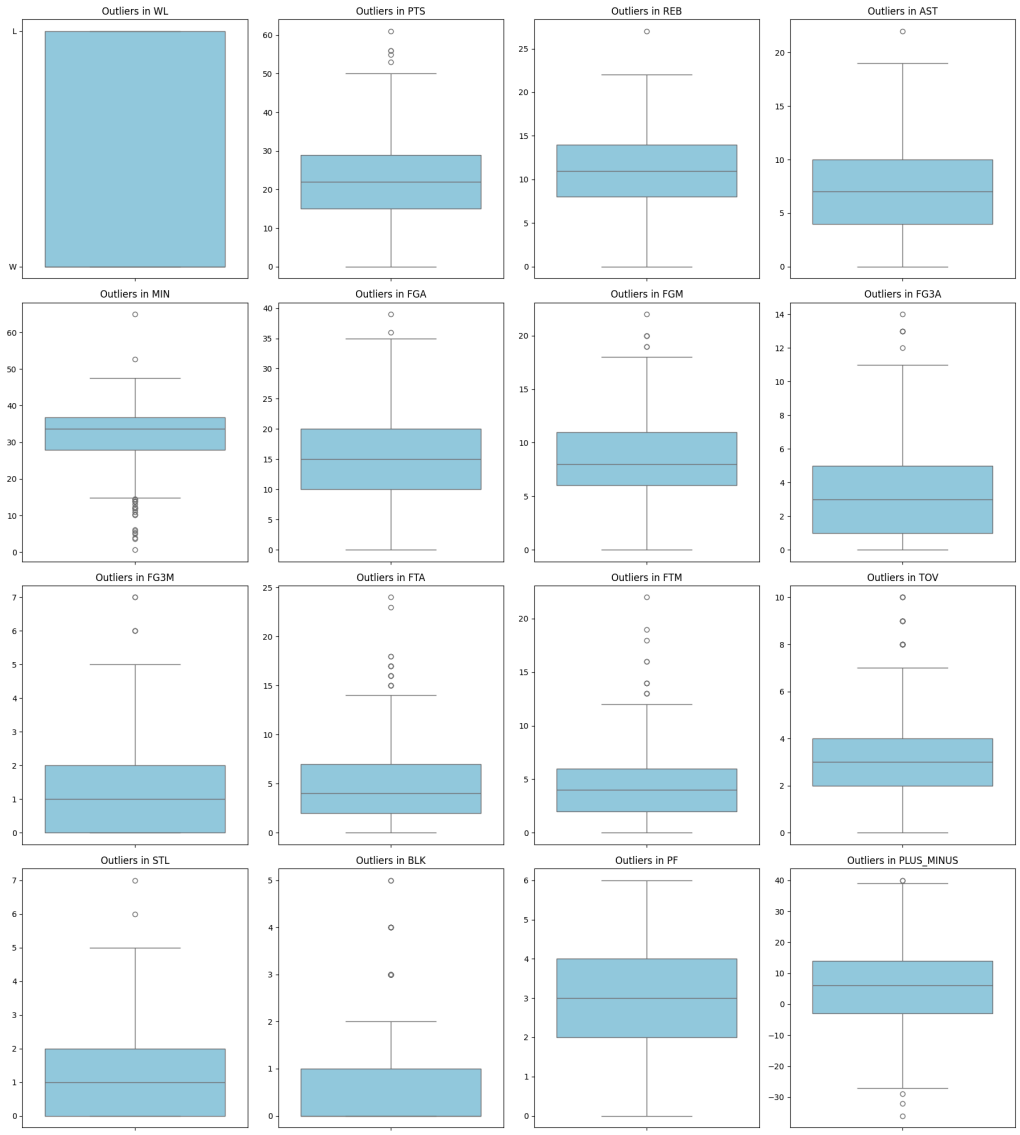

¿Cuál es la cardinalidad de las variables categóricas?

Muy baja, solamente tenemos dos variables categóricas:

- Resultado del partido (victoria, empate o derrota)
- Juegan de local o visitante

- Fecha del partido
    - Recordemos que tienden a jugarse en las mismas fechas los partidos, la temporada está muy marcada.
- Año de temporada

Por lo tanto, hay pocos valores únicos categóricos en el conjunto de datos.

Tipos de datos:

	0
SEASON_YEAR	object
GAME_DATE	object
WL	object
PTS	int64
REB	int64
AST	int64
MIN	float64
FGA	int64
FGM	int64
FG3A	int64
FG3M	int64
FTA	int64
FTM	int64
TOV	int64
STL	int64
BLK	int64
PF	int64
PLUS_MINUS	int64

¿Existen distribuciones sesgadas en el conjunto de datos? ¿Necesitamos aplicar alguna transformación no lineal?

Realizamos 3 histogramas enfocados a cada una de nuestras variables objetivo (puntos, rebotes y asistencias).

En la mayoría de ellas sí podemos observar un sesgo claro de los datos a la izquierda, son entendibles estos sesgos, debido a que son proporcionales al número de intentos, por ejemplo entre más intentos de tiro haga el jugador, más puntos tendrá, lo curioso es que estás variables muestran una correlación con los rebotes y asistencias, a mayor número de puntos, también incrementan sus números en rebotes y asistencias, creemos que es debido a la posición del jugador y a su buen rendimiento de juego.

A pesar de que otros datos muestran una tendencia más “acampanada”, como los minutos jugados (es normal que un jugador titular juegue ciertos números de minutos), o la ventaja del equipo (PLUS_MINUS) cuando el jugador está en cancha, sí podríamos aplicar algunas transformaciones no lineales como un “box-cox”.

Histograma de puntos

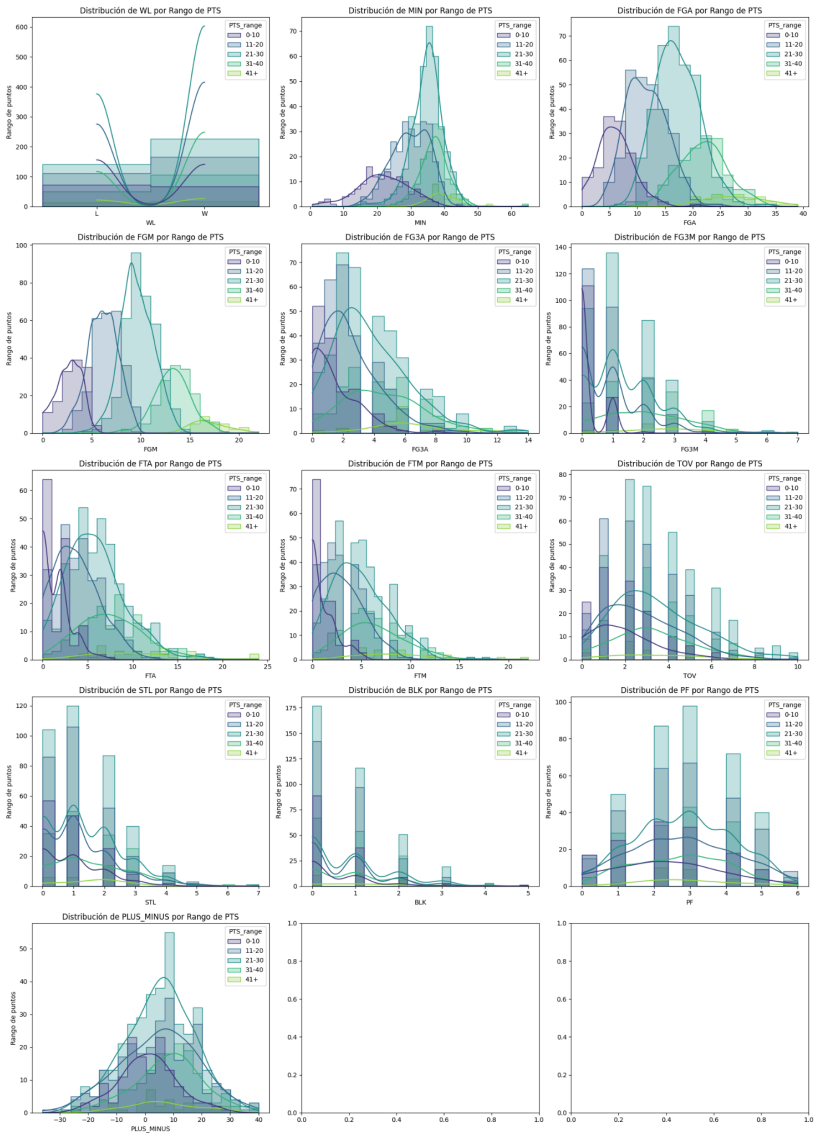

Histograma de asistencias

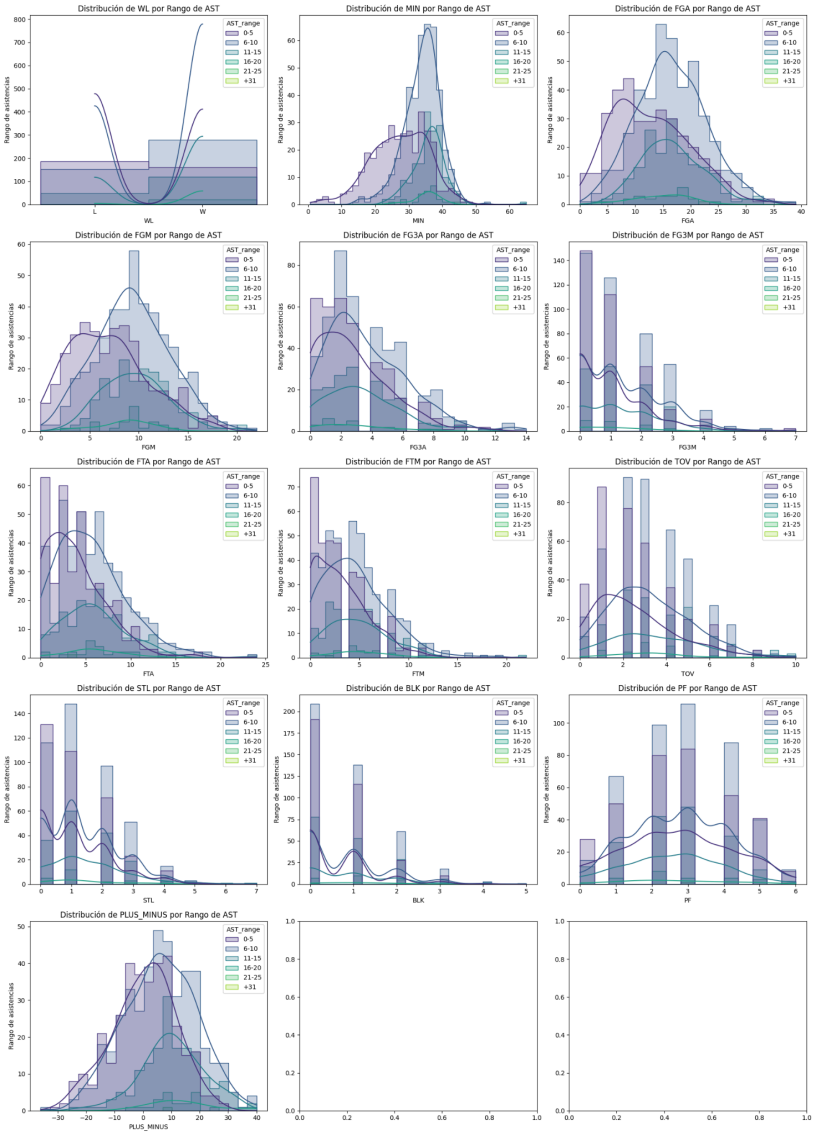

Histograma de rebotes

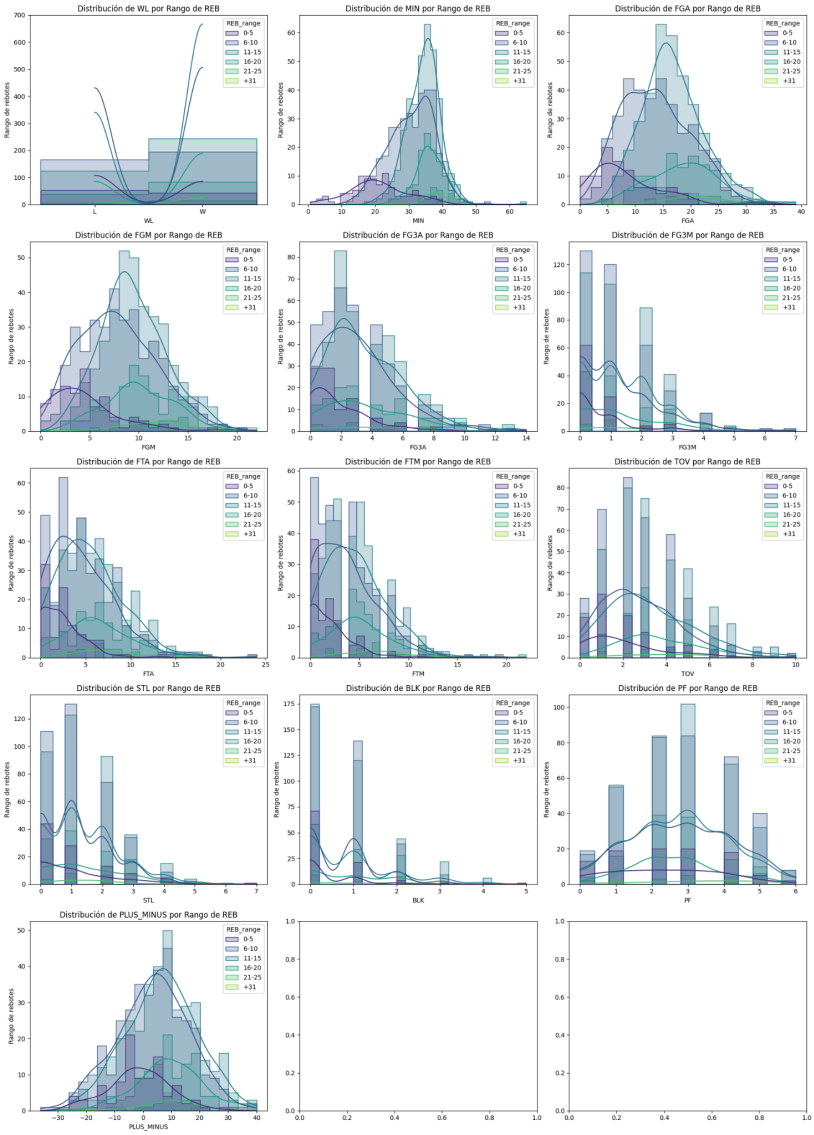

¿Se identifican tendencias temporales? (En caso de que el conjunto incluye una dimensión de tiempo)

Sí, podemos identificar cómo el jugador fue aumentando su promedio de las tres variables objetivo conforme avanzaban las temporadas, observando un pico sobre todo en puntos en la temporada (2020-2021).

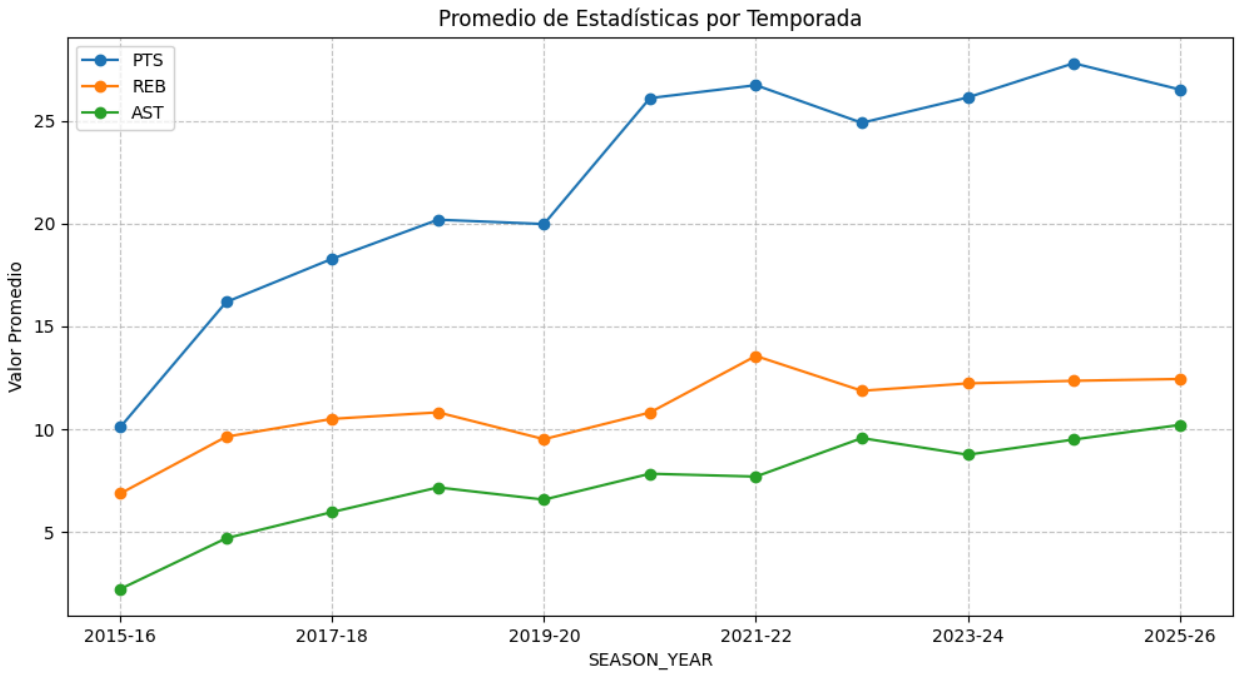

También podemos realizar el ejercicio con las victorias y derrotas, observando una clara tendencia a la baja por parte del equipo, esto conforme el jugador se volvía más experimentado en la liga, incluso en la temporada más baja de derrotas (2022-2023) es justo cuando el equipo logró su primer anillo de campeonato de la NBA.

PD: Curiosamente fue la temporada reciente que menos puntos realizó, en la que ganaron su primer anillo. “El talento gana partidos, pero el trabajo en equipo y la inteligencia ganan campeonatos” (Michael Jordan).

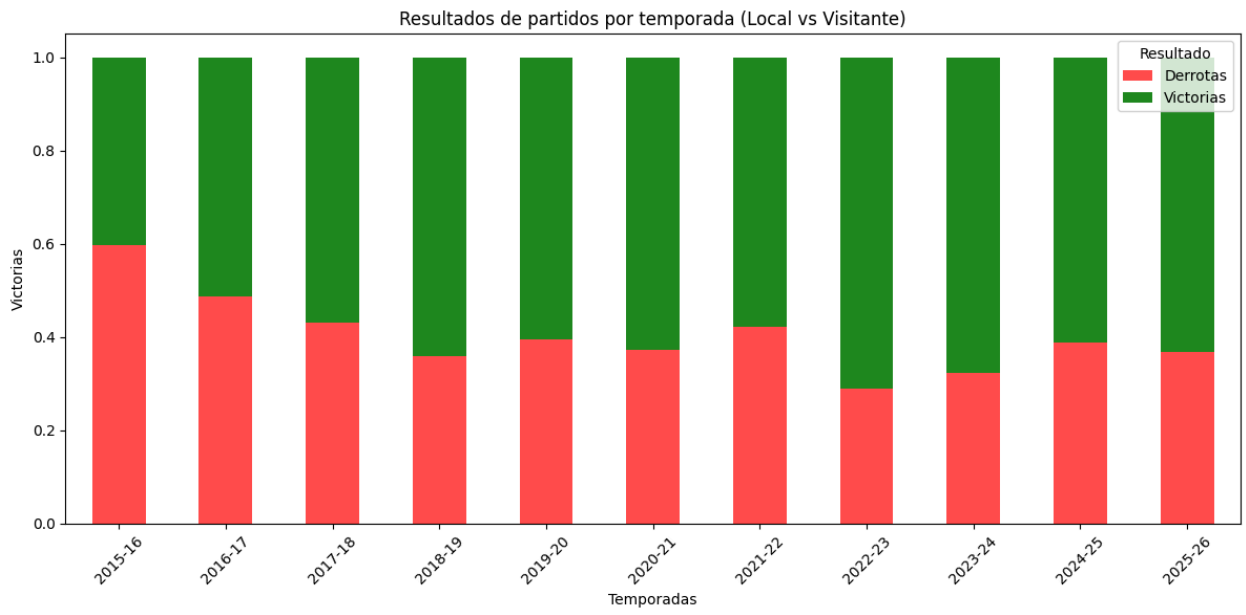

¿Hay correlación entre las variables dependientes e independientes?

Sí, las más claras son con el intento de tiros (generales, de 3 puntos y los tiros libres)y los puntos convertidos. Y los minutos en cancha, es necesario que el jugador juegue para que pueda sumar acciones.

Las más curiosas son las que comentamos anteriormente, como pueden influir en la cantidad de tiros realizados y anotados con las asistencias y rebotes completados.

Y la otra que llamó nuestra atención es la correlación de asistencias con la variable “PLUS_MINUS”, que es la que indica la diferencia de puntos del equipo contra el rival cuando el jugador está en cancha, nosotros lo interpretamos como la influencia que tiene el jugador en todo el equipo, para este jugador, es claro ver cómo Jokic hace jugar mejor a su equipo.

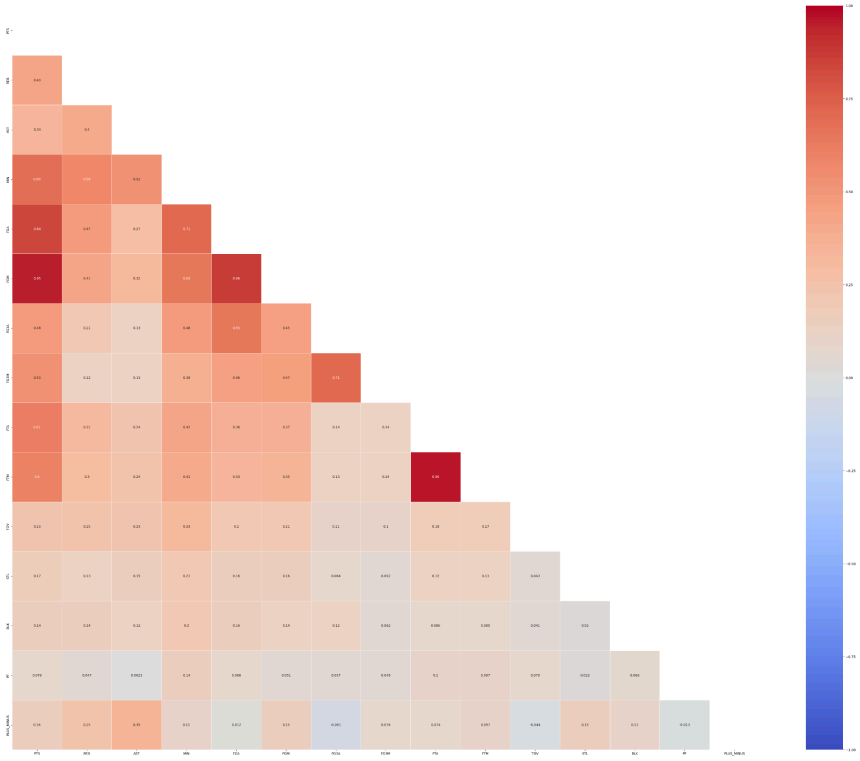

¿Cómo se distribuyen los datos en función de diferentes categorías? (análisis bivariado)

Nuestras categorías más importantes son las victorias, derrotas, días de descanso y el equipo al que se enfrentan (en los deportes hay claras tendencias de rendimiento de jugadores con algunos equipos), sin embargo, sólo contamos actualmente con victorias y derrotas, las otras variables las vamos a crear con una ingeniería de características.

Y como hemos visto en las gráficas anteriores, la derrota es parte “natural” del baloncesto, su influencia no es tan grande como en otros deportes, esto debido a la gran cantidad de partidos que se juegan, es decir, se pueden dar el lujo de perder algunos partidos incluso en las finales. Tan solo en la temporada donde salieron campeones, el equipo del jugador analizado perdió 27 partidos, y en la temporada donde despuntó como jugador, el equipo perdió 35 partidos, por lo tanto, no hay una distribución clara de los datos con las diferentes categorías. Probablemente se vea una tendencia más clara con los equipos enfrentados.

```python
season = "2022-23"
defeats = df[(df['SEASON_YEAR'] == season) & (df['WL'] == 'L')].shape[0]

print(f"En la temporada {season} hubo {defeats} derrotas")
```

```
En la temporada 2022-23 hubo 27 derrotas
```

```python
season = "2021-22"
defeats = df[(df['SEASON_YEAR'] == season) & (df['WL'] == 'L')].shape[0]

print(f"En la temporada {season} hubo {defeats} derrotas")
```

```
En la temporada 2021-22 hubo 35 derrotas
```

¿Hay desequilibrio en las clases de la variable objetivo?

En este caso no vamos a predecir clases, vamos a predecir valores numéricos (regresiones), es decir, queremos el valor de PTS, REB y AST que el jugador realizará en el siguiente partido.

Análisis Exploratorio de Datos (FÚTBOL - EQUIPOS)

Se tomó en cuenta el equipo del Arsenal (Inglaterra) y a partir de la temporada 2023 hasta la 2026.

Este mismo análisis teóricamente se podría aplicar a cualquier equipo.

¿Hay valores faltantes en el conjunto de datos?

Sí, por la naturaleza de los datos, el resultado de los partidos los clasificaba como:

- Victoria = True
- Derrota = False
- Empate = None

Esta era la columna que más podría llamar la atención por la cantidad de datos que marcaba como datos faltantes, sin embargo, con una transformación de los datos logramos identificar que no había ningún dato faltante.

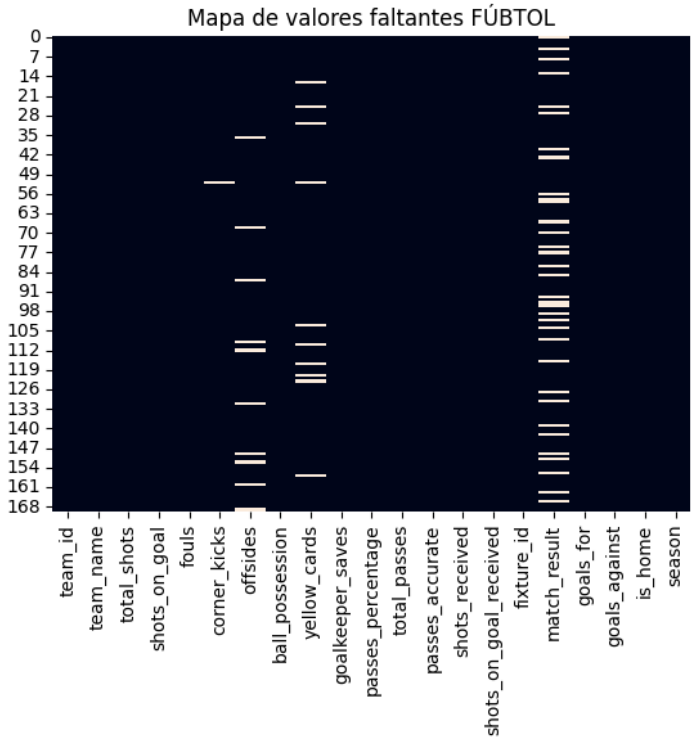

Por otro lado, hay ciertas columnas que sí tienen valores nulos, sin embargo, como veremos en los análisis más adelante, se pueden prescindir de ellas e incluso se optará por eliminarlas.

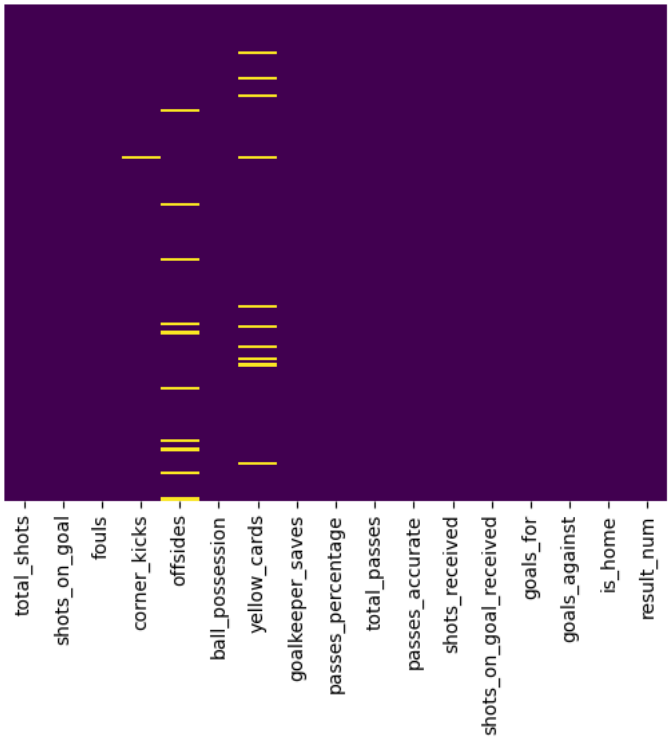

¿Se pueden identificar patrones de ausencia?

En los datos del equipo elegido, no.

No obstante, sí notamos que en algunas ligas menos conocidas (como la liga femenil mexicana), sí se encuentran datos de los resultados de los partidos (goles, resultado, fecha, etc), pero no se encuentran datos exactos de los partidos (posesión del balón, pases, tiros a puerta, etc).

Esto es una variable a tomar en cuenta a la hora de escoger qué datos se van a utilizar para crear un modelo.

¿Cuáles son las estadísticas resumidas del conjunto de datos?

Podemos observar valores atípicos interesantes, como que la máxima de goles anotados es 7 o la posesión del balón va del 23% al 81% con un promedio de 56%.

Los promedios son interesantes, ya que demuestran cómo lleva jugando el equipo a través de los años, por ejemplo, del Arsenal es bien sabido que llevan algunas temporadas haciendo las cosas bien, esto se observa en la media de goles anotados (2.05) y goles recibidos (0.8).

	count	mean	std	min	25%	50%	75%	max
total_shots	170.0	14.894118	5.376969	2.00	11.25	14.00	18.00	36.00
shots_on_goal	170.0	5.347059	2.658606	0.00	3.00	5.00	7.00	16.00
fouls	170.0	10.458824	3.784281	0.00	8.00	10.00	12.75	22.00
corner_kicks	169.0	6.177515	3.281146	1.00	3.00	5.00	8.00	17.00
offsides	160.0	1.956250	1.514487	0.00	1.00	2.00	3.00	7.00
ball_possession	170.0	0.566353	0.108288	0.23	0.49	0.57	0.65	0.81
yellow_cards	160.0	1.687500	1.249843	0.00	1.00	1.50	2.00	6.00
goalkeeper_saves	170.0	1.917647	1.600383	0.00	1.00	2.00	3.00	9.00
passes_percentage	170.0	0.854176	0.044010	0.70	0.83	0.86	0.88	0.93
total_passes	170.0	496.729412	118.784015	88.00	426.25	489.00	564.75	895.00
passes_accurate	170.0	428.329412	118.480207	69.00	357.00	418.50	486.75	827.00
shots_received	170.0	9.229412	4.598722	1.00	6.00	9.00	11.00	33.00
shots_on_goal_received	170.0	2.741176	1.738209	0.00	2.00	3.00	4.00	11.00
goals_for	170.0	2.052941	1.520128	0.00	1.00	2.00	3.00	7.00
goals_against	170.0	0.823529	0.838094	0.00	0.00	1.00	1.00	3.00

En datos categóricos es importante conocer cómo vienen clasificadas las victorias, para no caer en la trampa de olvidar los empates.

Nota: Match result se divide en

1. True: Partido ganado
2. False: Partido perdido
3. None: Partido empatado

```
df.drop(columns=['team_id', 'fixtu
```

	count	unique	top	freq
team_name	170	1	Arsenal	170
match_result	136	2	True	109
is_home	170	2	False	86

```
display(df['match_result'].value_
```

	count
match_result	
True	109
None	34
False	27

dtype: int64

¿Hay valores atípicos en el conjunto de datos?

Sí, pero en cantidades limitadas, dentro del fútbol (y en el deporte en general me atrevería a decir) hay estilos de juego que se pueden ver muy marcados en las estadísticas, y al nivel profesional hace que haya pocas anomalías estadísticas, como por ejemplo más de 8 atajadas del arquero.

Como mencionamos, no creemos que sea necesario eliminar los outliers, al contrario, estos pueden ayudar a prevenir el sobreajuste dentro del modelo.

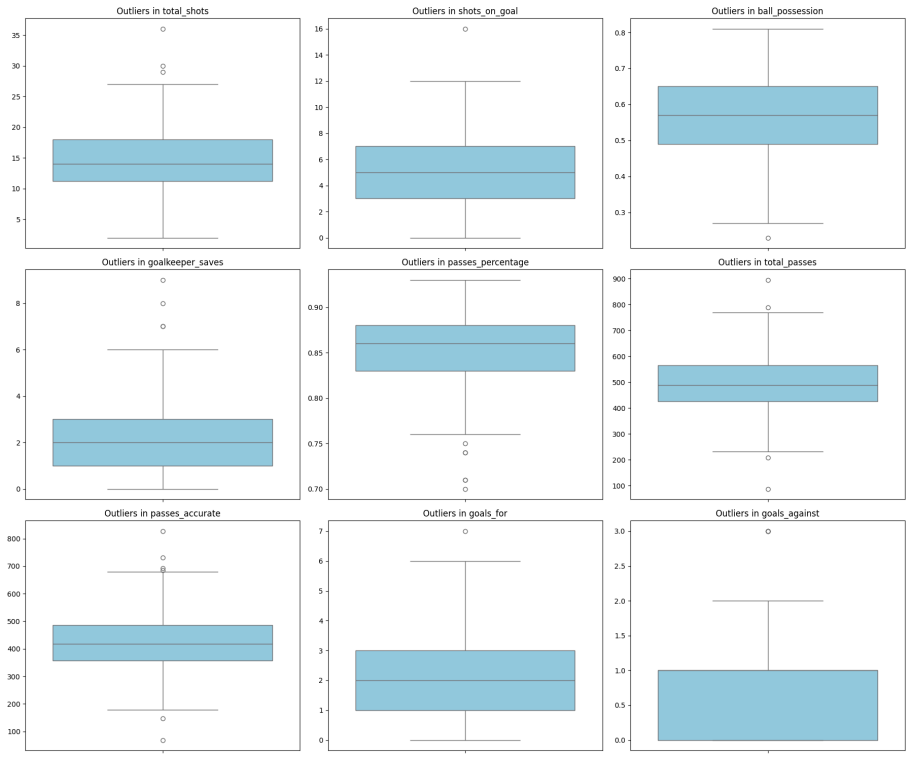

¿Cuál es la cardinalidad de las variables categóricas?

Muy baja, solamente tenemos dos variables categóricas:

- Resultado del partido (victoria, empate o derrota)
- Juegan de local o visitante

Por lo tanto, hay pocos valores únicos categóricos en el conjunto de datos.

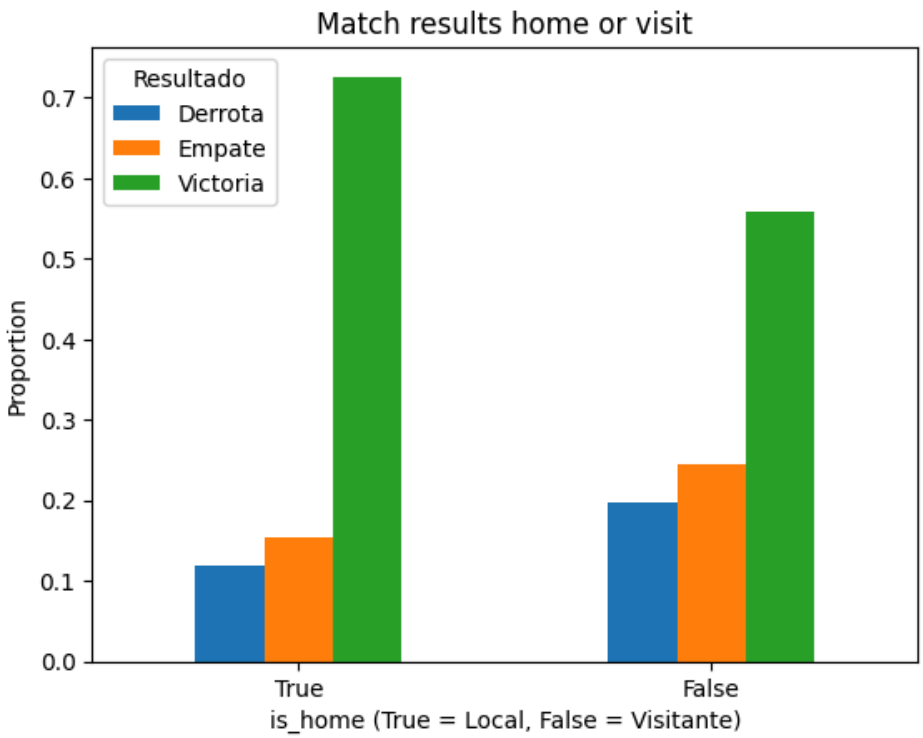

¿Existen distribuciones sesgadas en el conjunto de datos? ¿Necesitamos aplicar alguna transformación no lineal?

Como vemos en la imagen anterior, hay una ligera tendencia de victorias cuando el equipo juega de local (cabe señalar que esta tendencia ha ido bajando conforme a las décadas, pero aún es notable).

También en los histogramas podemos notar distribuciones sesgadas sobre todo en los goles anotados y en tiros a gol.

Por lo tanto, sí podríamos aplicar algunas transformaciones no lineales como un “box-cox”.

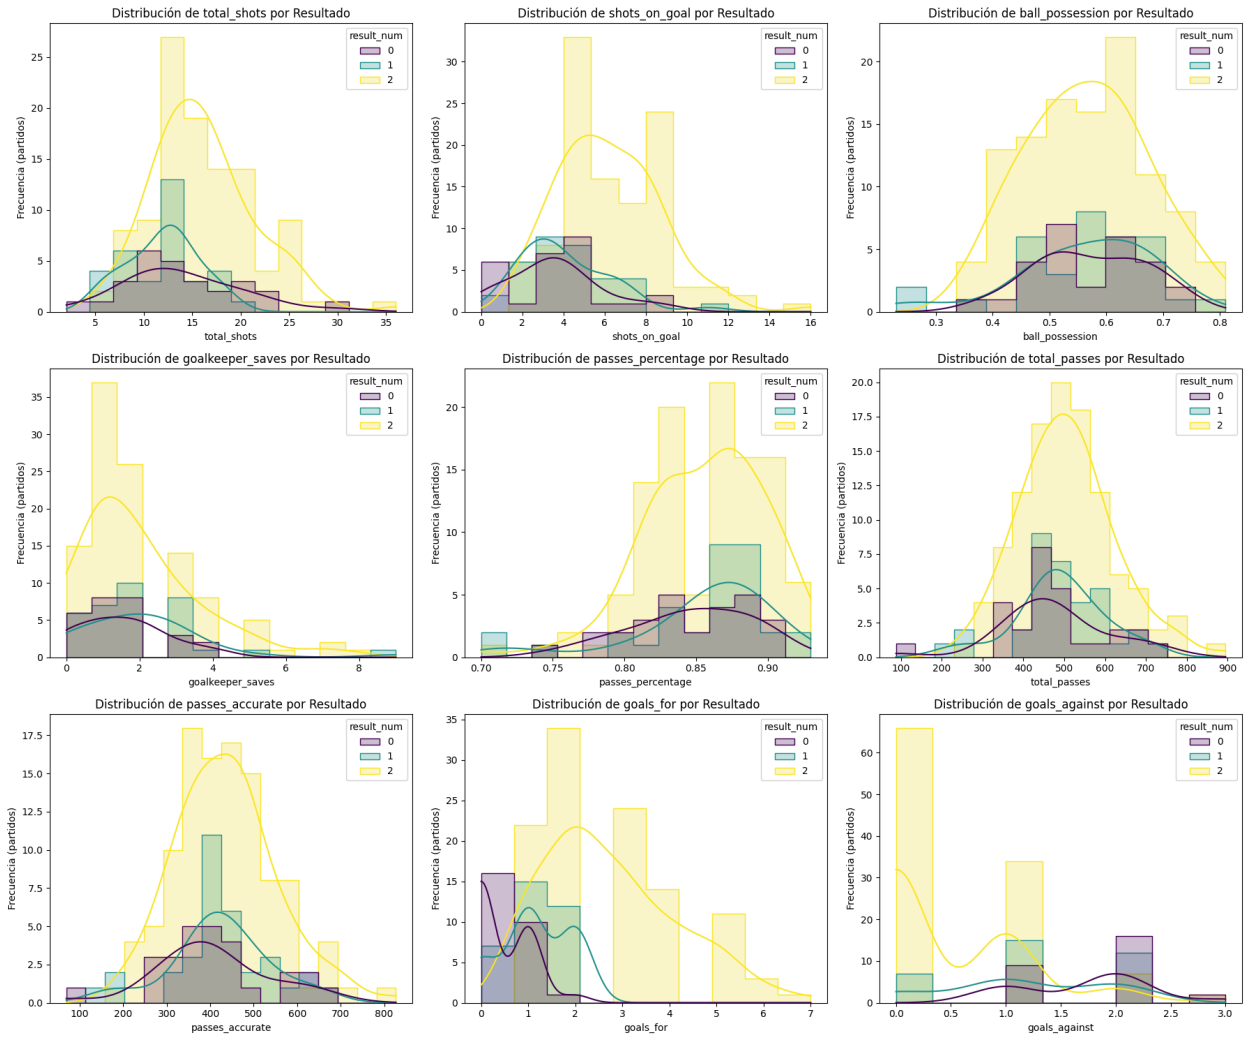

¿Se identifican tendencias temporales? (En caso de que el conjunto incluya una dimensión de tiempo).

Sí, en el deporte se pueden observar muchas tendencias, sobre todo girando en torno a las victorias, empates y derrotas de un equipo a través de los años, las rachas juegan un papel importante en la naturaleza de los deportes.

Por lo tanto, sería fácil perdernos analizando rachas deportivas, así que solo optamos por mostrar una gráfica que muestre los resultados (victorias, empates y derrotas) del equipo a lo largo de los años.

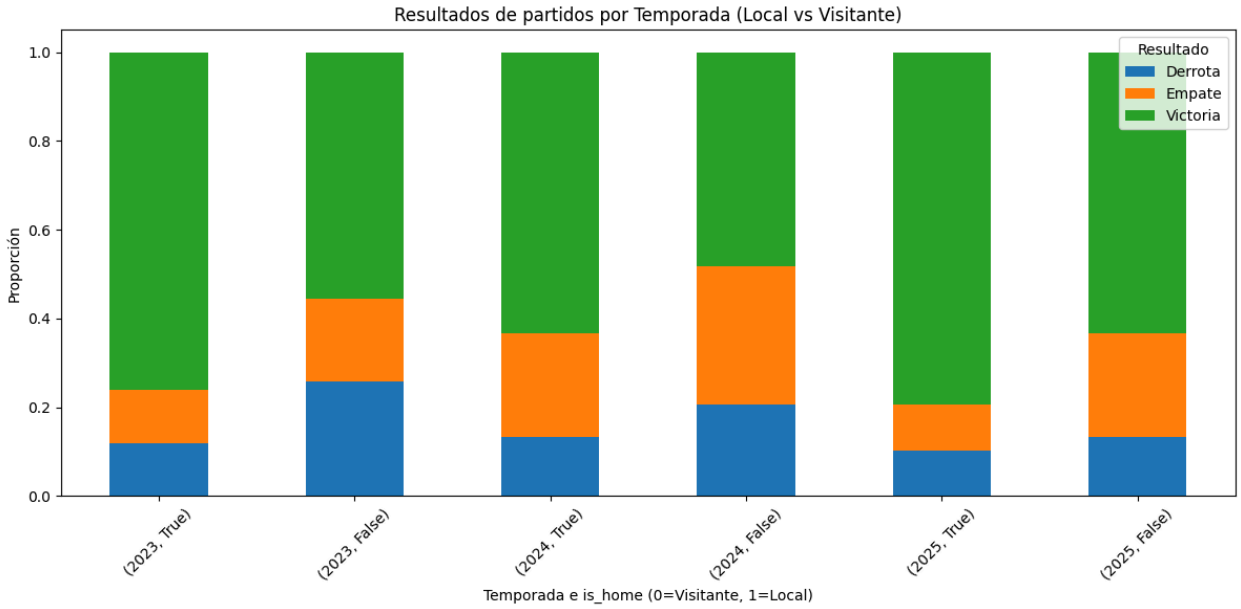

¿Hay correlación entre las variables dependientes e independientes?

Sí, encontramos una clara correlación entre los goles y tiros a puerto y el resultado del partido.

Sin embargo, lo más destacable, es que no encontramos una correlación directa fuerte en los datos con la posesión del balón y el resultado final. Es raro debido a que algunos estudios que leímos, mencionan que la posesión del balón y los tiros a puerta es un dato que influye en los equipos más ganadores (la verdad no es un gran descubrimiento, dado que en este deporte gana el que más goles anote, y si tiras más veces a portería tienes más oportunidades y para lograr eso necesitas tener más tiempo el balón).

Pero si se logra observar una correlación entre los tiros a puerta y la posesión del balón, por eso es importante tener el conocimiento de los datos junto con el contexto de los mismos, y no solo irnos con la gráfica obtenida.

Otras correlaciones interesantes que se derivan de los pases y los tiros a gol, son los tiros de esquina, entre más haya indica un mayor número de pases y de posesión. O una ligera correlación entre los goles en contra y las tarjetas amarillas.

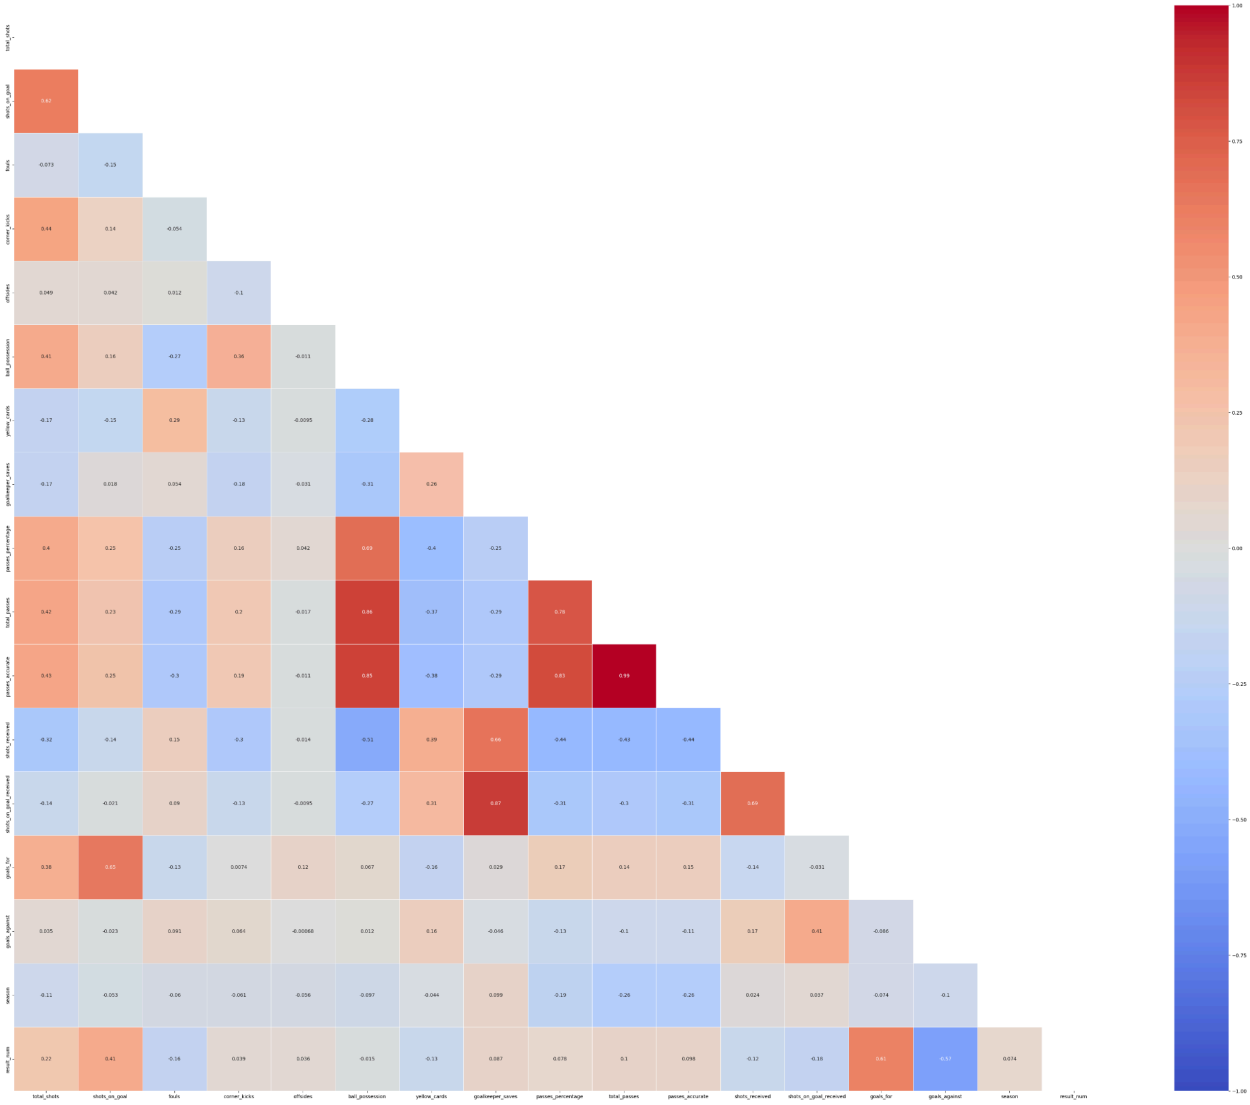

Para las siguientes gráficas de correlaciones, quisimos enfocarnos en el resultado del encuentro, para tener aún más claro aquellas correlaciones con las variables dependientes.

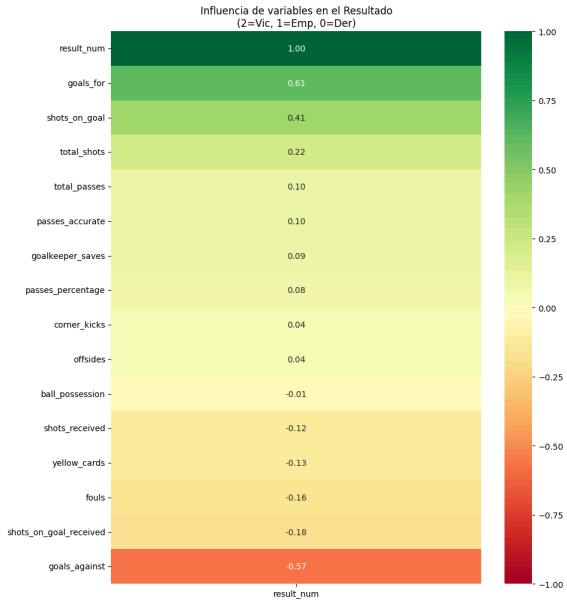

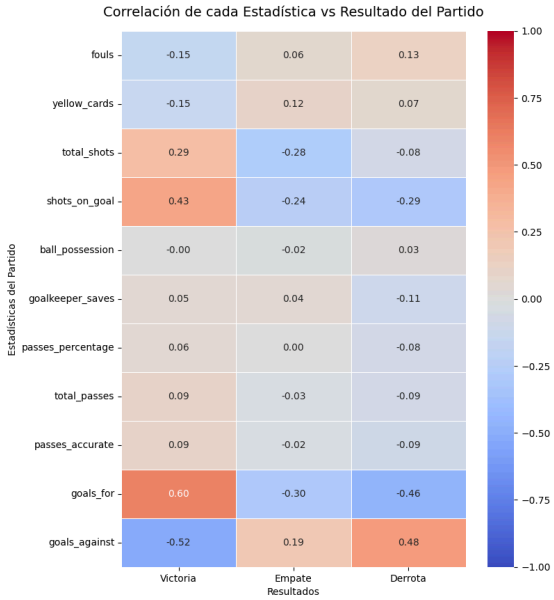

¿Cómo se distribuyen los datos en función de diferentes categorías? (análisis bivariado)

Como vimos en los histogramas, muchos datos tienden a tener la misma distribución sin importar si es victoria, empate o derrota, sobre todo las categorías de victoria y derrota, parece que tienden a seguirse, aún así la distribución de victorias no se aleja mucho, simplemente tiene distribuciones un poco más sesgadas a la izquierda si la variable requiere menos (salvadas por el portero) o la derecha si se necesitan más (tiros a puerta).

¿Hay desequilibrio en las clases de la variable objetivo?

Sí, pero no depende del equipo a analizar, como vimos en las gráficas de victorias, el Arsenal es un equipo que lleva varios años jugando bien y ganando mucho partidos, sin embargo, esto es un desequilibrio considerable, porque nuestro modelo podría estar sesgado a las victorias, caso contrario pasaría si analizamos Leicester City por ejemplo (un equipo que lleva dos años consecutivos bajando de división, es decir, quedando en los últimos lugares de la tabla de posiciones).

Por lo tanto, no estaría mal buscar un balance de clases de la variable objetivo (victoria, empate y derrota) con otros partidos de temporadas pasadas.

Referencias

Amazon Web Services. (2024). Amazon Comprehend Developer Guide. https://aws.amazon.com/comprehend/

Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32.

Galván Bellman, J. C., Méndez González, L. C., Pérez Olguín, I. J. C., & Quezada Carreón, A. E. (2024). Algoritmo de Machine Learning para la Predicción de un Partido de Futbol. *Revista Academia Journals*, 16(4).

GDELT Project. (2024). Global Database of Events, Language, and Tone. https://www.gdeltproject.org/

Google Cloud. (2024). Natural Language API Documentation. https://cloud.google.com/natural-language

Maher, M. J. (1982). Modelling association football scores. *Statistica Neerlandica*, 36(3), 109-118.

Microsoft Azure. (2024). Text Analytics Documentation. https://azure.microsoft.com/en-us/products/ai-services/text-analytics/

NewsAPI. (2024). News API Documentation. https://newsapi.org/

Visengeriyeva, L., Kammer, A., Bär, I., Kniesz, A., y Plöd, M. (2023). *CRISP-ML(Q). The ML Lifecycle Process*. MLOps. INNOQ. https://ml-ops.org/content/crisp-ml

La frase de Michael Jordan que explica a la perfección la importancia del trabajo en equipo - Elige Educar. (2017, 22 septiembre). Elige Educar. https://eligeeducar.cl/ideas-para-el-aula/la-frase-de-michael-jordan-que-explica-a-la-perfeccion-la-importancia-del-trabajo-en-equipo/