



INSTITUTO TECNOLÓGICO Y DE ESTUDIOS
SUPERIORES DE MONTERREY

MNA - Maestría Inteligencia Artificial Aplicada

Avance 3. Baseline

Jeanette Ríos Martínez **A01688888**

Ali Mateo Campos Martínez **A01796071**

Ali Alfonso Rico Vázquez **A01350630**

Docente Titular:

Dra. Grettel Barceló Alonso

Dr. Luis E. Falcón Morales

Docente Asistente:

Mtra. Verónica Sandra Guzmán de Valle

Asesor de proyecto:

Dr. Guillermo Mota Medina

Sports Bet Engine

24 Mayo 2026

Liga al GitHub	3
Baseline Fútbol	3
Justificación del algoritmo seleccionado	3
Análisis de características importantes	5
Subajuste y sobreajuste	5
Alineación de la métrica con los objetivos de negocio	6
Evaluación del desempeño mínimo aceptable	8
Baseline NBA	11
Justificación del algoritmo seleccionado	11
Análisis de características importantes	12
Subajuste y sobreajuste	13
Alineación de la métrica con los objetivos de negocio	16
Evaluación del desempeño mínimo aceptable	16
Referencias	18

Liga al GitHub

https://github.com/Alirico/Smart_Bet_Engine

Baseline Fútbol

Justificación del algoritmo seleccionado

Para el establecimiento del modelo baseline de fútbol soccer, se seleccionó una arquitectura paramétrica combinada basada en Regresión Lineal para la estimación de tasas de anotación y la Distribución de Poisson para la modelación de probabilidades.

Este enfoque se justifica para el problema de predicción de resultados deportivos por las siguientes variables:

- Tipo de Datos: El fenómeno opera sobre datos altamente estructurados como registros tabulares históricos de partidos, goles anotados y puntuaciones de rendimiento.
- Volumen de Datos: Con 41,641 registros, los modelos lineales nos ofrecen una convergencia matemática, ideal para procesar grandes volúmenes sin incurrir en los costos computacionales de arquitecturas más complejas en estas fases del proyecto.
- Naturaleza del Fenómeno: El fútbol se caracteriza por un volumen bajo de eventos discretos independientes (los goles) en un intervalo continuo de tiempo.

$$P(X = x) = \frac{\lambda^x e^{-\lambda}}{x!}$$

Donde la tasa lambda representa el promedio de goles esperados, que se proyecta mediante los regresores lineales usando el indicador de fuerza relativa entre los equipos.

En esta etapa del proyecto, interpretar se vuelve una prioridad del negocio, los coeficientes lineales permiten aislar y evaluar directamente el peso del factor de la localía (HFA) sobre la tasa de goles esperados.

El modelo baseline inicial para la disciplina de fútbol se estructuró utilizando una implementación de dos regresores lineales independientes entrenados de manera separada: modelo_local y modelo_visita. El objetivo inicial de estos modelos consiste en proyectar las tasas de goles esperados, a partir de las puntuaciones ELO históricas de los equipos y un factor fijo de ventaja de campo (HFA) establecido inicialmente en 53 puntos ELO. Posteriormente, estas tasas alimentaban una simulación basada en la distribución de Poisson para obtener las matrices de probabilidad de los tres posibles resultados de la quiniela: Local (1), Empate (X) y Visita (2).

Baseline (Avance 3)

df_train.head(2)

	fixture_id	season	date	home_team	away_team	home_goals	away_goals	Elo_Home_Pre	Elo_Away_Pre	Elo_Diff
0	738437	2021	2021-01-01 09:00:00+00:00	Sanna Khanh Hoa	Da Nang	2	3	1500.000000	1500.0	4.547474e-13
5	738442	2021	2021-01-03 09:00:00+00:00	Nam Dinh	Hoang Anh Gia Lai	1	1	1491.513739	1500.0	-8.486261e+00


Train

```
# 1. PREPARACIÓN DE DATOS
# Features: Usamos el Elo de ambos para capturar la diferencia de nivel
X_local = df_train[['Elo_Home_Pre', 'Elo_Away_Pre']]
y_local = df_train['home_goals']

# Para el visitante invertimos el orden lógico para el modelo
X_visita = df_train[['Elo_Away_Pre', 'Elo_Home_Pre']]
y_visita = df_train['away_goals']

# 2. ENTRENAMIENTO DEL MODELO POISSON
modelo_local = make_pipeline(StandardScaler(), PoissonRegressor())
modelo_visita = make_pipeline(StandardScaler(), PoissonRegressor())

modelo_local.fit(X_local, y_local)
modelo_visita.fit(X_visita, y_visita)
```



Análisis de características importantes

El diseño del baseline tiene un enfoque de selección de características de tipo Filtro basado en la teoría de sistemas de puntuación competitiva. Las variables predictoras críticas seleccionadas son:

- Elo_Home / Elo_Away: Puntuaciones que sintetizan el histórico acumulado de victorias, derrotas y calidad de los rivales previos de cada equipo.
- Home Field Advantage (HFA): Es un parámetro fijo de representación del sesgo geográfico y apoyo de la afición, inicialmente establecido en 53 puntos ELO con base en históricos.
- Representación Visual del Impacto y Sesgo de las Características: Para facilitar la interpretación del impacto de estas variables, la auditoría empírica de fronteras probabilísticas ejecutada sobre las 41,641 filas generó la siguiente distribución de densidad:

```
=== REPORTE DE DISTRIBUCIÓN DE FRONTERAS ===  
Partidos con diferencia <= 5%: 0  
Partidos con diferencia <= 10%: 21  
Partidos con diferencia <= 15%: 841  
Partidos con diferencia <= 20%: 41518  
Diferencia mínima absoluta en todo el dataset: 7.21%  
Diferencia promedio en todo el dataset: 16.03%
```

La interacción de las características nos indica que el parámetro HFA = 53 actúa como un sesgo dominante que desplaza de forma masiva la campana de distribución. El modelo lineal nos muestra que la diferencia de probabilidad en favor del local nunca baja del 7.21%, promediando un 16.03% de ventaja. Esto justifica metodológicamente la necesidad de calibrar la regla de decisión para rescatar la relevancia de la característica Elo_Away cuando el visitante es cualitativamente superior.

Subajuste y sobreajuste


Para evaluar la generalización del modelo, se contrastaron las métricas de rendimiento entre el conjunto de entrenamiento y el conjunto de prueba mediante validación cruzada interna e inspección de la estabilidad del error.

Se concluye una presencia de subajuste (Underfitting) estructural, debido a que las curvas de aprendizaje muestran que tanto el error de entrenamiento como el de prueba convergen rápidamente en un valor plano e idéntico, estabilizando el Accuracy global en 46.54% en test y rangos similares en entrenamiento.

Al ser modelos lineales independientes, los regresores carecen de la flexibilidad matemática necesaria (varianza) para capturar interacciones no lineales complejas entre las características. El modelo no está “memorizando”, por lo que no hay sobreajuste, pero sí hay algo de sesgo, lo cual es el comportamiento esperado y deseable de un baseline estricto.

Alineación de la métrica con los objetivos de negocio

Inicialmente se ejecutó la validación masiva sobre el universo del dataset de 41,641 partidos utilizando el criterio de decisión nativo de máxima probabilidad (`max()`), el sistema arrojó un Accuracy global del 45.00%. No obstante, el análisis minucioso del reporte de clasificación reveló un sesgo estructural donde: Clase Local (1): Concentró la totalidad de las predicciones, alcanzando un Recall del 98% al 100%. Clases Empate (X) y Visita (2): Registraron un Recall y F1-Score de 0.00, evidenciando un estado de letargo algorítmico donde el modelo era matemáticamente incapaz de diagnosticar victorias visitantes o escenarios de paridad.



Para corregir el sesgo sin alterar la naturaleza del baseline, se migró de la función de selección simple (`max()`) a un sistema de reglas de decisión definido por las tasas de consistencia empírica reales.

Se decidió ajustar la ventana de confianza para el visitante determinando que si este poseía un ELO superior y la ventaja probabilística del local era menor al 22%, el sistema otorgaría el voto a la Visita (2). De igual forma, se mapea la zona de paridad del modelo, capturando los partidos con menor diferencia en la probabilidad de victoria entre el local y el visitante (diferencias entre 7.21% y 14.0%) para asignarlos de manera orgánica al Empate (X).

```

# Para poder pasar al cálculo de accuracy, guardamos la decisión del modelo:
# REGLA 1: SI EL VISITANTE TIENE MEJOR ELO Y SU PROBABILIDAD SUPERA EL UMBRAL DEFINIDO
# Si el visitante es superior en ELO y la diferencia de probabilidades es menor a 0.22,
# asumimos que tiene los argumentos deportivos para romper la localía.
dif_prob = prob_victoria_local - prob_victoria_visita

#Regla 1, empate si la diferencia de probabilidad es muy corta entre 7.21% y 14% que es el mínimo de diferencia del dataset
if 0.0721 <= dif_prob <= 0.14:
    resultado_predicho = "X"

#Regla 2, cuando ELO del visitante es mayor al local y la diferencia de probabilidades es menor a 22%
elif elo_equipo_B > elo_equipo_A and dif_prob < 0.22:
    resultado_predicho = "2" # Predicción formal: Victoria Visitante

#Regla 3, cuando la probabilidad de victoria es mayor para el visitante
elif prob_victoria_visita > prob_victoria_local:
    resultado_predicho = "2" # Predicción formal: Victoria Visitante

# REGLA 4: CONDICIÓN COMPLEMENTARIA PARA EL LOCAL
# Si no se cumple lo anterior, pero el local mantiene la ventaja probabilística tradicional,
elif prob_victoria_local > prob_victoria_visita:
    resultado_predicho = "1" # Predicción formal: Victoria Local

# REGLA 5: CASOS DE EXCEPCIÓN por defecto
else:
    resultado_predicho = "1"

return resultado_predicho

```

Evaluación del desempeño mínimo aceptable

En el contexto del proyecto, los entornos donde no existe un modelo previo o donde se apuesta bajo una heurística aleatoria establecen un desempeño mínimo de referencia del 33.33% de Accuracy.

Asimismo, una heurística ingenua basada en favorecer siempre al local debido a la ventaja de casa arroja un límite histórico de entre el 42 % y 44 % de efectividad dependiendo de la liga.


El Desempeño Mínimo Requerido que buscamos es 44 % de Accuracy Global con capacidad de predicción multiclase. Y el rendimiento del Baseline propuesto por el modelo desarrollado alcanza un 46.54% de Accuracy Global en el conjunto de prueba.

Se obtuvieron los siguientes resultados:

Accuracy Global en Test: 46.54%

=== REPORTE DE CLASIFICACIÓN ===

	precision	recall	f1-score	support
Local (1)	0.49	0.74	0.59	18835
Empate (X)	0.21	0.01	0.02	8343
Visita (2)	0.41	0.37	0.39	14463
accuracy			0.47	41641
macro avg	0.37	0.37	0.33	41641
weighted avg	0.41	0.47	0.41	41641



El F1-Score de la visita cambió de estar en 0 hasta un sólido 0.39, logrando un equilibrio entre precisión (41%) y recall (37%). El empate registró una precisión del 21%.

Lejos de degradar el comportamiento del sistema, la introducción de criterios analíticos realistas elevó el Accuracy Global del 45.00% al 46.54%. Nuestro objetivo es tratar de alcanzar un 66%, esto para poder cubrir por lo menos 2 de los 3 posibles resultados.

El baseline supera con éxito tanto la barrera del azar como la heurística ingenua de localía. Al registrar métricas vivas y estables en las tres dimensiones de la quiniela (F1-score de 0.59, 0.02 y 0.39 respectivamente), el modelo baseline demuestra alcanzar un nivel de madurez técnica aceptable.

Baseline NBA

Justificación del algoritmo seleccionado

Debido a una cantidad decente de datos que podemos obtener por jugador (si es veterano cerca de 800 u 900 juegos), podemos optar por modelos de machine learning, para este ejercicio optamos por hacer una búsqueda en grilla de los principales modelos para establecer nuestra línea base.

Escogimos modelos clásicos que sabemos que pueden funcionar debido a la naturaleza del proyecto, es decir, un problema de regresión: Árboles de regresión, regresión (Ridge y máquina de vector) y una red neuronal sencilla.

Sabemos que una búsqueda en grilla nos puede ahorrar tiempo en probar diferentes modelos con el mismo conjunto de datos.

La búsqueda en cuadrícula, o Grid Search, es una técnica de optimización de hiper parámetros que se utiliza en el aprendizaje automático.

Esta técnica realiza una búsqueda a través de un subconjunto especificado de hiper-parámetros de un algoritmo de aprendizaje automático. El objetivo de la búsqueda en cuadrícula es encontrar la combinación de hiper parámetros que produzca el mejor rendimiento del modelo.

```

param_grids = {
    'Ridge': {
        'regressor__alpha': [0.01, 0.1, 1.0, 10.0, 50.0, 100.0, 200.0]
    },
    'RandomForest': {
        'regressor__n_estimators': [50, 100, 200],
        'regressor__max_depth': [None, 4, 5, 6, 8, 10, 12, 20],
        'regressor__min_samples_split': [2, 5, 10, 15],
        'regressor__min_samples_leaf': [2, 4, 6],
        'regressor__max_features': ['sqrt', 'log2', None]
    },
    'XGBoost': {
        'regressor__n_estimators': [50, 100, 200, 300],
        'regressor__learning_rate': [0.01, 0.03, 0.05, 0.1],
        'regressor__max_depth': [3, 4, 5, 6, 7],
        'regressor__subsample': [0.7, 0.8, 1.0],
        'regressor__colsample_bytree': [0.7, 0.8, 1.0],
        'regressor__reg_lambda': [1, 5, 10]
    },
    'SVR': {
        'regressor__kernel': ['linear', 'rbf'],
        'regressor__C': [0.01, 0.1, 0.5, 1.0, 5.0, 10.0],
        'regressor__epsilon': [0.1, 0.2, 0.5, 1.0],
        'regressor__gamma': ['scale', 'auto', 0.1, 0.01]
    },
    'RedNeuronal': {
        'regressor__hidden_layer_sizes': [(16,), (32,), (64,), (32, 16), (16, 8)],
        'regressor__activation': ['relu', 'tanh'],
        'regressor__alpha': [0.001, 0.01, 0.1, 1.0]
    }
}

```

Análisis de características importantes

En este conjunto de datos, tenemos muchos datos del jugador que podrían provocar un filtrado de información dependiendo de la variable que deseamos predecir, como la tasa de éxito de puntos, es algo que no podemos darle al modelo ya que está medida ya está tomando los puntos anotados.

Por lo tanto, se decidió incluir las siguientes columnas para entrenar los modelos.

Cabe destacar que de escoger como modelo los árboles de regresión, no solo sería más sencillo observar que variables influyen más en la predicción, si no que debido a la naturaleza y su ventaja de explicabilidad del modelo, podríamos trazar un camino de la predicción.

```

features_input = [
    # Básicos
    'MIN',          # Minutos de juego .

    # Tiros (volumen + eficiencia)
    'FGA',          # Tiros de campo intentados
    'FGM',          # Tiros de campo convertidos
    'FG3A',         # Tiros de 3 intentados
    'FG3M',         # Tiros de 3 convertidos
    'FTA',          # Tiros libres intentados
    'FTM',          # Tiros libres convertidos

    # Contexto del partido
    'IS_HOME',      # ¿Juegan de local?
    'DAYS_REST',    # Días de descanso

    # Otras estadísticas
    'TOV',          # Pérdidas de balón (Turnovers).
    'STL',          # Robos de balón (Steals).
    'BLK',          # Tapones realizados (Blocks).
    'PF',           # Faltas personales (Personal Fouls).
    'PLUS_MINUS',   # Diferencia de puntos del equipo cuando el jugador está en cancha.

    # Promedios históricos
    'H2H_PTS_AVG', 'H2H_AST_AVG', 'H2H_REB_AVG',

    # Datos de los rivales
    'OPP_PTS_ALLOWED_AVG', 'OPP_REB_ALLOWED_AVG',
    'OPP_AST_ALLOWED_AVG', 'OPP_FG_PCT_ALLOWED_AVG'
]

```

Subajuste y sobreajuste

Decidimos aplicar la búsqueda en grilla para los 3 valores objetivos, así que tenemos 3 entrenamientos y por lo tanto 3 modelos para:

- Puntos
- Rebotes
- Asistencias

Nuestra métrica para evaluar el sub/sobre-ajuste fue el **MAE (Error medio absoluto)**, el cual nos indica en promedio, cuánto se alejan las predicciones de nuestro modelo de los valores reales.

Es decir, si en el modelo de puntos tenemos un MAE de 2, quiere indicar que en promedio nuestro modelo se equivoca por 2 puntos más o menos. En ese caso, una predicción de puntos se debería leer como “El modelo predijo que Lebron James anotará 23 puntos esta noche, con un rango de 21 a 25” y en base a esto se realizaría la apuesta.


Podemos observar las gráficas y métricas de nuestro MAE, observando que en algunos casos el MAE es más alto en el entrenamiento que en los datos de prueba, esto podría indicar un error en nuestro modelo, como por ejemplo:

- Conjunto de pruebas pequeño
- El conjunto de datos de prueba es “más fácil” que el de entrenamiento
- Regularización intensiva
- Fuga de datos
- Sobre-ajuste
- Sub-ajuste

Por lo tanto, optamos por elegir como modelos de línea base, aquellos cuyo MAE en entrenamiento sea más alto que en el de prueba y que no sea igual a 0.


Puntos:

--- Resultados Finales ---				
Modelo	Train MAE	Test MAE	Test RMSE	
Ridge	0.00	0.00	0.00	
SVR	0.00	0.03	0.04	
RedNeuronal	0.14	0.36	0.53	
XGBoost	0.03	0.43	1.23	
RandomForest	0.33	1.01	1.93	




Rebotes

--- Resultados Finales ---				
Modelo	Train MAE	Test MAE	Test RMSE	
Ridge	10.67	2.74	3.43	
SVR	10.74	2.77	3.45	
RandomForest	2.80	2.90	3.61	
XGBoost	9.06	2.91	3.61	
RedNeuronal	5.73	3.05	3.86	



Asistencias

--- Resultados Finales ---				
Modelo	Train MAE	Test MAE	Test RMSE	
Ridge	7.73	2.44	3.17	
SVR	7.39	2.46	3.16	
XGBoost	4.05	2.50	3.26	
RandomForest	2.22	2.53	3.27	
RedNeuronal	4.14	2.72	3.42	



Alineación de la métrica con los objetivos de negocio

El **error absoluto medio** es un muy buen indicador para evaluar nuestro modelo, nos da la oportunidad de establecer umbrales (sobre todo un umbral mínimo) de las acciones del jugador, y en base a esto, poder hacer la puesta.

Aquí lo interesante es apostar a que el jugador logrará llegar o romper el umbral predicho.

No se busca apostar a un número cerrado de una determinada acción (Lebron anotará exactamente 13 puntos, por ejemplo) debido al caos que puede haber en la propia naturaleza humana y del deporte.

Buscamos tener un parámetro (Lebron anotará entre 10 y 15 puntos), para de esta forma poder apostar que el jugador pasará o no pasará cierta barrera, aquí la pregunta que surge es ¿Qué es lo más lucrativo? ¿Qué es lo más estable? ¿Qué es lo más arriesgado?

Otra métrica básica a incorporar es la **RMSE** el cual eleva al cuadrado los residuos antes de promediarlos, lo cual penaliza más los errores grandes que los pequeños. Esta sensibilidad nos puede ayudar a identificar los errores grandes de predicción.

Por último podríamos aplicar el **coeficiente de determinación** para observar en un valor numérico la interpretación de nuestro modelo, esta métrica arroja un valor de 0 a 1, un valor de 1 indica que el modelo explica perfectamente la variabilidad de los datos.

Evaluación del desempeño mínimo aceptable

Análisis del desempeño obtenido

Puntos

Definitivamente fue el modelo que tiene el error más aceptable, un error de un punto en la predicción (considerando el modelo que parece ser más estable), no es un problema

es las apuestas, ya que normalmente se puede apostar a que un jugador anotará más de X puntos, es un error que puede beneficiar bastante.

Rebotes y asistencias

En los dos se muestran errores de 3 y 2.5, algo que sí es preocupante, debido a que hay partidos donde los jugadores solamente hacen 3 u 2 rebotes y asistencias respectivamente, si en promedio este es el error, no tendríamos ninguna ventaja y sería como dejarlo al azar, esto claro considerando predicciones menores a 3.

¿Cuál debería ser el desempeño mínimo a obtener?

Buscamos obtener un **MAE (error absoluto medio)**, es decir, un promedio de errores de las predicciones **menor a 2**, sobre todo en rebotes y asistencias.

Con un MAE ideal (lo ideal, pero no el objetivo del proyecto) de 1 o menor, otra vez, sobre todo en rebotes y asistencias, debido a que son estadísticas que en el basquetball suelen estar por 1, 2 o 3 dependiendo del jugador y la posición.

Referencias

Leidwein, F. (2025). *How to Build an ELO Rating System for the Premier League in Python*. Recuperado de:

<https://statsultra.com/how-to-build-an-elo-rating-system-for-the-premier-league-in-python/>

Amazon Web Services. (2024). Amazon Comprehend Developer Guide. <https://aws.amazon.com/comprehend/>

Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32.

Galván Bellman, J. C., Méndez González, L. C., Pérez Olguín, I. J. C., & Quezada Carreón, A. E. (2024). Algoritmo de Machine Learning para la Predicción de un Partido de Fútbol. *Revista Academia Journals*, 16(4).

GDELT Project. (2024). Global Database of Events, Language, and Tone. <https://www.gdeltproject.org/>

Google Cloud. (2024). Natural Language API Documentation. <https://cloud.google.com/natural-language>

Maher, M. J. (1982). Modelling association football scores. *Statistica Neerlandica*, 36(3), 109-118.

Microsoft Azure. (2024). Text Analytics Documentation. <https://azure.microsoft.com/en-us/products/ai-services/text-analytics/>

NewsAPI. (2024). News API Documentation. <https://newsapi.org/>

Visengeriyeva, L., Kammer, A., Bär, I., Kniesz, A., y Plöd, M. (2023). *CRISP-ML(Q). The ML Lifecycle Process*. MLOps. INNOQ. <https://ml-ops.org/content/crisp-ml>

